Práctica 3: Análisis de vínculos con PageRank, HITS y PageRank Sensible a Tópico

Esteva Gallegos Carlos Fabián León Navarrete Adam Edmundo

Munive Ramírez Ibrahim

Datos Masivos II — Lic. en Ciencia de Datos

4 de noviembre de 2026

Resumen

Se implementan en el paradigma MapReduce, sobre PySpark, los algoritmos PageRank, HITS y PageRank Sensible a Tópico, y se aplican a tres grafos de tamaños muy distintos: la red de citas cit-HepPh, la red de colaboraciones de artistas de Spotify y los enlaces entre artículos de la Wikipedia en inglés (1.5 millones de artículos y 90 millones de enlaces después de la poda). Se describen los algoritmos, el tratamiento de los datos (en particular, la reducción del grafo de Wikipedia), la validación contra implementaciones de referencia y los rankings obtenidos. PageRank recupera los nodos centrales que uno esperaría (la Segunda Guerra Mundial y Estados Unidos en Wikipedia, Bach en Spotify, artículos clásicos de 1992–93 en hep-ph). HITS, en cambio, concentra casi toda su masa en una sola comunidad densa: dimensiones extra en hep-ph, hip hop y reguetón en Spotify, y la demografía de Estados Unidos en Wikipedia. El PageRank sensible a tópico se vuelve interpretable cuando se mide relativo al PageRank global.

1. Introducción

El análisis de vínculos asigna importancia a los nodos de una red a partir de su estructura. PageRank [5] lo modela como un paseante aleatorio, HITS [2] separa a los nodos en *hubs* y *autoridades*, y el PageRank Sensible a Tópico [1] sesga el teletransporte hacia un conjunto de páginas de un tema. La referencia principal del curso es el capítulo 5 de [4].

El objetivo es aplicar los tres algoritmos a los tres conjuntos de datos y comparar sus resultados. Todo el código y los datos procesados viven en el repositorio del proyecto.

2. Algoritmos en MapReduce

2.1. PageRank

Con N nodos, factor de amortiguamiento $\beta = 0.85$ y M la matriz de transición, el vector de rangos cumple

$$r = \beta M r + \frac{1-\beta}{N}\mathbf{1}. \tag{1}$$

Cada iteración es un MapReduce: el *map* emite, por cada arista $u \to v$, el par $(v, r_u/d_u)$; el *reduce* suma por destino y aplica la fórmula de arriba. Como en la sección 5.2 de [4], se usa el caso en que el vector de rangos cabe en la memoria de cada tarea (N valores de 8 bytes: 12 MB con los 1.5 millones de nodos de Wikipedia), mientras que la matriz M (90 millones de aristas) se queda distribuida. Los nodos sin aristas de salida (*colgantes*) reparten su masa D de forma uniforme:

$r_v \leftarrow \beta s_v + (1-\beta)/N + \beta D/N$, de modo que $\sum_v r_v = 1$ en todo momento. Las trampas de araña quedan cubiertas por el teletransporte. Se itera hasta $\|r_t - r_{t-1}\|_1 < 10^{-8}$ o 100 iteraciones.

2.2. Papel del hash

Las aristas (u, v) se **particionan una sola vez por hash del nodo origen** u (`repartition(P, "src")`) y cada partición se guarda en caché como dos arreglos de enteros (origen, destino). Así cada tarea tiene completas las listas de salida de sus nodos y conoce su grado. En cada ronda:

1. el vector r (dividido entre los grados) se **difunde** (*broadcast*) a todas las tareas;
2. **map + combiner**: cada tarea recorre sus aristas y acumula localmente las contribuciones r_u/d_u por destino (`np.bincount`), de modo que emite un solo vector parcial de N sumas en vez de un par por arista;
3. **reduce**: las P particiones se agrupan sin *shuffle* (`coalesce`) en tantas tareas como núcleos; cada tarea suma ya los vectores de sus bloques (un segundo nivel de *combiner*) y el driver suma solo esos pocos vectores.

Una ronda es entonces un único trabajo de Spark, sin *join* ni *shuffle* por arista. Una primera versión con *joins* de RDD entre enlaces y rangos (ambos particionados por el mismo hash) tardaba unos 13 s por iteración en cit-HepPh; con el vector difundido baja a ∼1 s, y en Wikipedia completa una iteración de PageRank sobre 90 millones de aristas toma 1.7 s. El hash también se usa en la ingesta: cada título de Wikipedia se reemplaza por un hash de 64 bits, de modo que las aristas son pares de enteros y no hace falta un *join* título→id sobre cientos de millones de enlaces. El número de particiones P es un compromiso: cada tarea devuelve un vector de N valores, así que muchas particiones aumentan el tráfico del reduce (se usaron $P = 8$ en los grafos chicos y $P = 32$ en Wikipedia).

2.3. HITS

Cada ronda tiene dos pasos MapReduce sobre las mismas aristas particionadas: autoridad $a_v = \sum_{u \to v} h_u$ (se suma por destino, como en PageRank) y hub $h_u = \sum_{u \to v} a_v$ (se suma por origen; equivale a multiplicar por $L^\top$ sin construir el grafo transpuesto). Después de cada paso se normaliza a norma L_2 con una reducción global. La convergencia se mide con la suma de las distancias L_1 de a y h entre rondas.

2.4. PageRank Sensible a Tópico

Para cada tópico t con conjunto semilla S_t, el teletransporte salta solo a S_t:

$$r_t = \beta M r_t + (1-\beta)\frac{\mathbf{e}_{S_t}}{|S_t|}. \tag{2}$$

Los T vectores se calculan a la vez: el rango es una matriz $N \times T$ que se difunde completa, así que un solo recorrido de las aristas calcula las contribuciones de todos los tópicos. En Wikipedia completa la matriz no cabe cómoda en memoria y los tópicos se procesan en grupos de 3 columnas. La masa de los nodos colgantes de cada tópico también vuelve a S_t. En la consulta se combinan con pesos w_t: $r = \sum_t w_t r_t$.

3. Datos

3.1. cit-HepPh

Red de citas de arXiv hep-ph (SNAP) [3]: 34 546 artículos y 421 534 citas, de 1992 a 2003. Dirigida, citante → citado. Los ids del archivo de aristas no tienen ceros a la izquierda y el archivo de fechas no cubre todos los papers, por lo que el año se obtiene del id de arXiv. Para leer los rankings, los títulos de los 3 388 artículos que aparecen en los primeros 1 000 lugares de algún ranking se obtuvieron de la API pública de arXiv. **Tópicos:** periodos de publicación (1992–94, 1995–97, 1998–2000, 2001–03), con entre 4 423 y 11 751 semillas.

3.2. Spotify

Red de colaboraciones entre artistas (Kaggle): 156 320 artistas y 300 379 colaboraciones. La red es no dirigida y se convierte en un grafo dirigido simétrico (dos aristas por colaboración, 600 758 en total). Se eliminaron ids duplicados y 7 aristas hacia artistas inexistentes. **Tópicos:** 9 macro-géneros por palabras clave sobre `genres` (de 702 semillas en metal a 18 171 en pop).

3.3. Wikipedia

Dump `enwiki` (117 GB = 110 GiB, MediaWiki 1.47). Procesamiento:

1. **Ingesta (map):** el XML se parte por rangos de bytes en bloques de 64 MiB (1 756 bloques), con la misma regla que usa Hadoop para los *splits*: cada página pertenece al bloque donde empieza su etiqueta `<page>`. Cada bloque es una tarea de Spark que lee su rango del disco y, con expresiones regulares, extrae título, redirect, enlaces `[[...]]` y categorías (solo espacio de nombres 0, sin el texto). Cada título se identifica con un hash de 64 bits. Cada tarea escribe su propio parquet, así que la ingesta se puede reanudar bloque por bloque si se interrumpe. La primera versión (`newAPIHadoopFile` con delimitador `</page>`) procesaba 7.6 MB/s; leyendo los rangos directamente en las tareas de Python se llegó a 71–80 MB/s con 8 núcleos: el dump completo se procesa en 23–26 minutos (antes se estimaban 3.4 horas).
2. **Limpieza de referencias:** antes de extraer los enlaces se quitan las citas bibliográficas (`<ref>...</ref>` y plantillas `{{cite ...}}`). Sin este paso, los enlaces a periódicos y editoriales que aparecen en las citas (*The Guardian*, *Oxford University Press*, *The Washington Post*) entraban al top-20 de PageRank, aunque no dicen nada del tema de los artículos.
3. **Grafo:** de 7 113 361 artículos y 12 037 823 redirects se obtienen 206 400 127 enlaces entre artículos. Se resuelven redirects, se conservan solo destinos que son artículos y se eliminan auto-lazos y repetidos. Se excluyen listas y páginas de desambiguación.
4. **Poda de relevancia:** se eliminan, de forma iterativa, los artículos con menos de k enlaces entrantes ($k = 10$ en el dump completo, $k = 3$ en la muestra). En el dump completo la poda converge en 8 rondas (de 122.9 a 90.4 millones de aristas).

Tópicos: 10 macro-tópicos (arte y cultura, ciencia, deportes, geografía, historia, negocios, política, religión, salud, tecnología) a partir de palabras clave en las categorías de cada artículo. Las palabras se buscan al inicio de palabra, para evitar falsos positivos como *sport* dentro de *transport* o *nfl* dentro de *conflicts*. Los conjuntos semilla van de 38 738 artículos (ciencia) a 425 518 (deportes, 28 % del grafo).

Se trabajó con dos versiones. La **muestra** son los primeros 6 GiB del dump (96 bloques, 212 209 artículos); sirvió para desarrollar y probar el código. Como el dump está ordenado por id de página, la muestra no es aleatoria: contiene los artículos más antiguos, entre ellos miles de artículos de pueblos de Estados Unidos creados en 2002 a partir del censo. Los resultados principales son los del **dump completo**. La Tabla 1 resume los tamaños.

Tabla 1: Tamaño de los grafos procesados.

Dataset	Nodos	Aristas	Nodos sin salida
cit-HepPh	34 546	421 534	2 393
Spotify	156 320	600 758	2 999
Wikipedia (muestra)	153 242	6 780 563	26
Wikipedia (completo)	1 516 230	90 351 624	117

4. Validación

Las implementaciones se verificaron con el grafo de tres nodos del libro (PageRank exacto $(7/33, 5/33, 21/33)$ con $\beta = 0.8$), donde el error máximo fue de 6×10^{-14}, y comparándolas con `networkx` en cit-HepPh y Spotify (Tabla 2). Para HITS, `networkx` normaliza a suma 1, así que los vectores propios se reescalan antes de comparar. En todos los casos la diferencia absoluta máxima es menor a 10^{-7}. La correlación de Spearman del PageRank por tópico en cit-HepPh (0.984) es más baja solo porque el 69 % de los nodos tiene rango prácticamente cero para el periodo 1992–94: las citas apuntan al pasado, así que desde los artículos de 1992–94 no se llega a los posteriores, y el orden entre esos valores casi nulos es ruido numérico. Además, en los cuatro grafos se verificó que PageRank y cada vector por tópico suman 1, que los vectores de HITS tienen norma L_2 igual a 1 y que no hay valores negativos.

Tabla 2: Comparación con `networkx`: diferencia absoluta máxima y correlación de Spearman.

	cit-HepPh		Spotify	
Algoritmo	máx. $\lvert\Delta\rvert$	Spearman	máx. $\lvert\Delta\rvert$	Spearman
PageRank	3.1×10^{-8}	1.000	3.1×10^{-9}	1.000
HITS (hubs)	1.1×10^{-9}	1.000	4.4×10^{-12}	1.000
HITS (autoridades)	9.7×10^{-9}	0.9999	4.8×10^{-12}	1.000
PageRank por tópico (1.er tópico)	4.6×10^{-8}	0.984	3.5×10^{-8}	0.9999

5. Resultados

5.1. Rankings

Las Tablas 3–5 muestran los primeros lugares de cada ranking. Las tablas completas (top-20, con grados) están en `results/tablas/`.

Wikipedia. PageRank da los temas generales que casi cualquier artículo puede citar: guerras mundiales, países, ciudades, el fútbol y la Iglesia católica. Las autoridades de HITS, en cambio, son casi todas páginas de demografía de Estados Unidos (censo, grupos étnicos, umbral de pobreza, códigos FIPS), y los hubs son los artículos que más enlazan a ellas: Estados Unidos, sus estados y ciudades, y las páginas de años y décadas recientes. Esto se explica porque decenas de miles de artículos de localidades estadounidenses tienen una sección de demografía con los mismos enlaces, lo que forma un bloque muy denso del grafo. En la muestra el efecto es todavía más fuerte: el top de PageRank incluye *United States Census Bureau*, *Geographic Names Information System* y *Per capita income*, y todos los hubs son pueblos de Nueva Jersey, Pensilvania y Virginia. Entre muestra y dump completo coinciden 8 de los 20 primeros de PageRank (56 de los 100 primeros), pero solo 2 de los 20 primeros hubs.

Tabla 3: Wikipedia completa: top-10 de PageRank, autoridades y hubs.

	PageRank	Autoridad	Hub
1	World War II	2020 United States census	United States
2	Association football	U.S. state	Hispanic and Latino Americans
3	United States	Race and ethnicity in the United States census	2025 in the United States
4	United Kingdom	United States Census Bureau	Demonym
5	World War I	African Americans	21st century
6	New York City	World War II	New York (state)
7	France	Native Americans in the United States	2020s
8	Catholic Church	Federal Information Processing Standards	Tennessee
9	London	Hispanic and Latino Americans	New Jersey
10	India	Poverty threshold	Jersey City, New Jersey

Tabla 4: Spotify: top-10 de PageRank y de HITS (en un grafo simétrico, hubs y autoridades coinciden).

	PageRank	Grado	HITS	Grado
1	Johann Sebastian Bach	1 781	Farruko	284
2	Traditional	1 371	French Montana	320
3	Jean Sibelius	580	Gucci Mane	509
4	Mc Gw	858	Ty Dolla $ign	252
5	HaKokhav HaBa (programa israelí)	377	De La Ghetto	193
6	MC MN	632	Lil Wayne	273
7	John Williams	415	Chris Brown	245
8	A.R. Rahman	463	Snoop Dogg	495
9	Armin van Buuren	513	Arcángel	169
10	Andrea Bocelli	342	J Balvin	205

Spotify. PageRank sigue casi al grado: los primeros son compositores clásicos (cuyas obras se graban con cientos de intérpretes), el pseudo-artista *Traditional* (canciones de autor anónimo), productores de funk brasileño (Mc Gw, MC MN) y un concurso de televisión israelí. HITS se concentra en un solo grupo de artistas de hip hop y reguetón que colaboran mucho entre sí, aunque ninguno sea el de mayor grado.

Tabla 5: cit-HepPh: top-5 de PageRank, autoridades y hubs (id de arXiv `hep-ph/...`).

	PageRank	Autoridad	Hub
1	CTEQ Parton Distributions and Flavor Dependence of Sea Quarks (9303255)	The Hierarchy Problem and New Dimensions at a Millimeter (9803315)	Testing the Nature of Kaluza-Klein Excitations at Future Lepton Colliders (9909232)
2	Total cross sections (9209205)	New Dimensions at a Millimeter to a Fermi and Superstrings at a TeV (9804398)	The Beyond the Standard Model Working Group: Summary Report (0204031)
3	Erratum: Power corrections $1/Q^2$ to parton sum rules... (9310316)	Phenomenology, Astrophysics and Cosmology of Theories with Sub-Millimeter Dimensions... (9807344)	Theories in More than Four Dimensions (0008333)
4	Constraints From Gauge Coupling Unification On The Scale Of Supersymmetry Breaking (9206203)	Quantum Gravity and Extra Dimensions at High-Energy Colliders (9811291)	Theory and Phenomenology of Type I strings and M-theory (0006190)
5	P-Wave Charmonium Production in B-Meson Decays (9208254)	A Large Mass Hierarchy from a Small Extra Dimension (9905221)	Gauge Coupling Unification with Extra Dimensions... (9906431)

cit-HepPh. Los primeros de PageRank son artículos de 1992–93. El dataset solo contiene citas entre artículos de 1992 a 2003, así que los artículos más viejos tienen más tiempo para ser citados y, como sus propias referencias quedan fuera del dataset, casi no tienen aristas de salida. El 4.º lugar tiene solo 32 citas, pero lo citan artículos muy importantes: es un ejemplo de que PageRank no es solo el grado. Las autoridades son los artículos fundacionales de las *dimensiones extra* de 1998–99: los de Arkani-Hamed, Dimopoulos y Dvali, y el de Randall y Sundrum (9905221). Los hubs son revisiones y trabajos de 1999–2002 sobre el mismo tema. También se cuela una fe de erratas (9310316), que probablemente se cita junto con el artículo que corrige.

5.2. PageRank vs. HITS vs. grado

La Tabla 6 compara los rankings. PageRank está muy correlacionado con el grado de entrada en todos los grafos (ρ de 0.74 a 0.91), pero su top-20 solo coincide parcialmente con el del grado, salvo en Spotify (17 de 20). La correlación entre PageRank y hubs es nula: un hub es un nodo que *cita* mucho, no uno citado. Lo más notable es lo poco que coinciden los top-20 de PageRank y de autoridades (de 1 a 9 de 20): HITS refleja una comunidad, no la importancia global. La Tabla 7 lo cuantifica: el 1 % de nodos con mayor autoridad concentra del 92 al 99.6 % de la masa L_2 del vector, mientras que el 1 % más alto de PageRank acumula solo entre el 20 y el 28 % de la masa.

La Figura 1 muestra las distribuciones de grado. Todas tienen colas pesadas: unos pocos nodos reciben miles de enlaces (*Association football* recibe 97 199 en Wikipedia), lo que explica por qué PageRank y el grado de entrada están tan correlacionados.

Tabla 6: Correlación de Spearman entre rankings y coincidencias en el top-20.

	Spearman				Top-20 en común	
Dataset	PR–grado ent.	PR–aut.	PR–hub	aut.–hub	PR y aut.	PR y grado
cit-HepPh	0.910	0.665	−0.008	0.481	1	3
Spotify	0.785	−0.035	−0.035	1.000	2	17
Wikipedia (muestra)	0.899	0.431	−0.012	0.687	9	15
Wikipedia (completo)	0.735	0.573	0.135	0.568	3	15

Tabla 7: Concentración de los rankings: fracción de nodos con autoridad mayor a 10^{-6} y masa del 1 % de nodos más alto.

Dataset	Aut. $> 10^{-6}$	Masa L_2 de aut. (top 1 %)	Masa de PageRank (top 1 %)
cit-HepPh	0.743	0.917	0.196
Spotify	0.667	0.966	0.226
Wikipedia (muestra)	0.951	0.996	0.202
Wikipedia (completo)	0.996	0.983	0.279

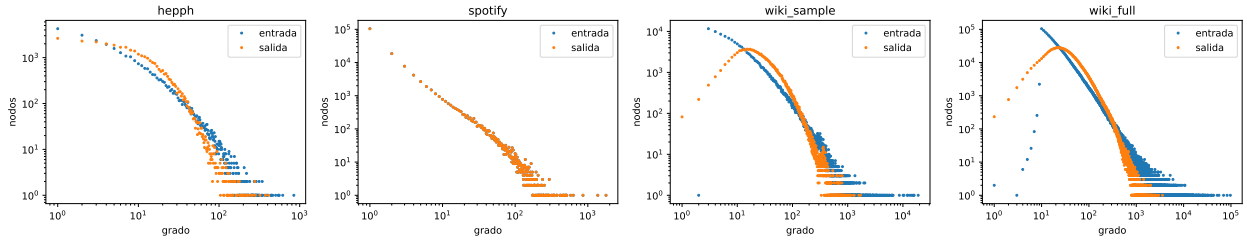


Figura 1: Distribución de grados de entrada y salida (escala log-log). En Spotify ambas coinciden porque el grafo es simétrico; en Wikipedia el grado de entrada tiene una cola mucho más larga que el de salida, y el corte en 10 es efecto de la poda.

5.3. Sensibilidad a tópico

En Wikipedia, el top de cada tópico en bruto sigue dominado por los nodos con mayor PageRank global (Estados Unidos y la Segunda Guerra Mundial aparecen en los primeros lugares de los 10 tópicos). Esto se debe a que los conjuntos semilla son grandes y a que esos artículos reciben enlaces de todas partes. Aun así, el sesgo se nota: en ciencia suben *Genus*, *Mathematics*, *Species* y *Carl Linnaeus*, y en política los partidos Demócrata y Republicano. Para aislar el efecto del tópico se usa el *lift* $r_t(v)/\mathrm{PR}(v)$ entre los 1 000 primeros de cada tópico, es decir, cuánto gana un artículo cuando el paseante salta solo a las semillas del tema (Tabla 8). Con esta medida aparecen artículos claramente del tema: cantantes de *playback* del cine indio, taxonomía de insectos, posiciones del fútbol, divisiones administrativas de Canadá, unidades militares, partidos de la India, cargos eclesiásticos, términos médicos y revistas de videojuegos.

Tabla 8: Wikipedia completa: primeros 4 artículos por *lift* r_t/PR entre el top-1 000 de cada tópico.

Tópico	Artículos
Arte y cultura	K. J. Yesudas; S. Janaki; K. S. Chithra; S. P. Balasubrahmanyam
Ciencia	Fauna Hawaiiensis; Cosmopterigidae; Thomas de Grey, 6th Baron Walsingham; Paleoart
Deportes	Tercera División; ESPN3; Midfielder; Defender (association football)
Geografía	Classification of municipalities in Quebec; Historical federal electoral districts of Canada; Regional county municipality; Canadian provincial electoral districts
Historia	Division (military); Regiment; United Kingdom constituencies; Brigade
Negocios	Professional Darts Corporation; Darts; Kabushiki gaisha; Privately held company
Política	None of the above (India); Janata Party; None of the above; Communist Party of India
Religión	Eminence (style); Titular bishop; Bibliotheca (Apollodorus); Suffragan bishop
Salud	Psychological thriller; Oral administration; Trauma center; Residency (medicine)
Tecnología	Single-player video game; Famitsu; GamePro; Electronic Gaming Monthly

En cit-HepPh los tópicos son periodos, y como las citas van hacia atrás en el tiempo, cada tópico favorece a lo que citaban los artículos de ese periodo. Para 1992–94 el primer lugar es *Towards the Theory of Cosmological Phase Transitions* (9203203); para 2001–03 sube al primer lugar *The Hierarchy Problem and New Dimensions at a Millimeter* (9803315), y entra al top-5 un artículo de 1992 sobre rompimiento de supersimetría con una dimensión interna grande (9211309), antecedente de las ideas de dimensiones extra.

Ejemplo de consulta. En Spotify, un usuario interesado en música latina y hip hop usaría $w_{\text{latino}} = w_{\text{hip hop}} = 0.5$. El top-5 resultante es Elis Regina, Redimi2, Ñengo Flow, Alex Zurdo y Farruko, muy distinto del PageRank global (Bach, Traditional, Sibelius). Como cada r_t ya está calculado, la consulta es solo una suma ponderada de columnas y no requiere volver a iterar.

5.4. Convergencia

La Tabla 9 y la Figura 2 resumen la convergencia. PageRank y su versión por tópico convergen a 10^{-8} en 49–95 iteraciones, con un decaimiento geométrico cercano a β^t. Spotify es el más lento (95 iteraciones de PageRank y 100 por tópico, que se quedan en 1.5×10^{-8}), probablemente porque un grafo simétrico tiene componentes bipartitas y entonces el segundo valor propio de la matriz de Google es exactamente $\pm\beta$. HITS no tiene teletransporte y su velocidad depende de la separación entre los dos primeros valores singulares de L: solo converge en la muestra de Wikipedia (41 rondas); en los demás grafos llega a las 100 rondas con distancias de 8×10^{-6} (cit-HepPh), 3×10^{-8} (Spotify) y 8×10^{-7} (Wikipedia completa). Los rankings ya son estables a ese nivel, como muestra la comparación

con `networkx`. En Wikipedia completa, el PageRank por tópico es la parte más cara (752 s), porque cada grupo de 3 tópicos recorre las aristas por separado.

Tabla 9: Iteraciones y tiempo de cada algoritmo (8 núcleos, 15 GB de RAM; el tiempo total incluye la carga del grafo).

	PageRank		HITS		Por tópico		Total
Dataset	iter.	s	iter.	s	iter.	s	s
cit-HepPh	49	36	100	153	55	45	245
Spotify	95	77	100	163	100	116	360
Wikipedia (muestra)	53	32	41	46	56	70	177
Wikipedia (completo)	58	99	100	323	61	753	1 420

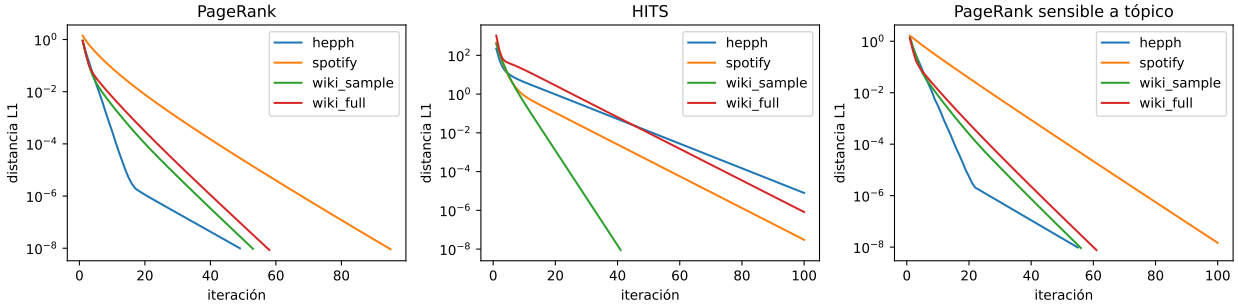


Figura 2: Distancia L_1 entre iteraciones consecutivas (escala logarítmica).

En los grafos chicos el costo por iteración (∼0.7 s en cit-HepPh) lo domina la sobrecarga de lanzar un trabajo de Spark, no el cálculo; en Wikipedia completa, con 200 veces más aristas, la iteración de PageRank solo sube a 1.7 s.

6. Discusión

- En Spotify la red es simétrica: hubs y autoridades coinciden, y PageRank es casi proporcional al grado (en un grafo no dirigido sin teletransporte lo sería exactamente). El nodo *Traditional* no es un artista real, y convendría quitarlo en un análisis más fino.
- HITS sufre del efecto de comunidad densa (*tightly-knit community*): el vector propio principal se concentra en el bloque más denso del grafo y casi todos los demás nodos quedan con valores cercanos a cero. Por eso sus autoridades en Wikipedia son páginas del censo de Estados Unidos y no los temas más importantes. PageRank, gracias al teletransporte, reparte la masa de forma mucho más uniforme.
- En Wikipedia solo se cuentan enlaces escritos en el wikitext (no los generados por plantillas), y se quitaron los enlaces dentro de las citas bibliográficas. Comparado con la corrida que sí los incluía, 15 de los 20 primeros de PageRank se mantienen, y los que salen son periódicos y editoriales.
- La muestra de Wikipedia es un prefijo del dump ordenado por id de página, no una muestra aleatoria; por eso sus rankings están sesgados hacia los artículos más antiguos (pueblos de Estados Unidos creados en masa a partir del censo) y coinciden solo en parte con los del dump completo.
- Los tópicos se definen por palabras clave en categorías o géneros, lo que es una aproximación. Aparecen errores esperables: *corporation* mete a la *Professional Darts Corporation* en negocios,

psycholog mete a *Psychological thriller* en salud, y el tópico de deportes es tan grande (28 % de los artículos) que se parece al PageRank global.

- En cit-HepPh, el ranking tiene un sesgo de edad por la ventana de tiempo del dataset: los artículos de 1992–93 acumulan citas y casi no tienen aristas de salida, porque lo que ellos citan quedó fuera.

7. Conclusiones

- Los tres algoritmos se implementaron como rondas MapReduce en PySpark, con las aristas particionadas una vez por hash del origen y el vector de rangos difundido. Coinciden con `networkx` con errores menores a 10^{-7} y escalan al grafo completo de Wikipedia (1.5 millones de nodos, 90 millones de aristas) en unos 24 minutos para los tres algoritmos y los 10 tópicos.
- La parte más costosa fue la ingesta del dump de 117 GB. Partirlo por rangos de bytes en tareas independientes y reanudables bajó el tiempo de 3.4 horas estimadas a menos de media hora.
- PageRank da rankings interpretables y estables en los tres grafos, muy correlacionados con el grado de entrada pero no idénticos: premia que te enlacen nodos importantes.
- HITS identifica comunidades densas más que importancia global (dimensiones extra en hep-ph, hip hop y reguetón en Spotify, demografía de Estados Unidos en Wikipedia), y converge más despacio.
- El PageRank sensible a tópico permite responder consultas por tema combinando vectores ya calculados. Cuando los conjuntos semilla son grandes, su efecto se ve mejor relativo al PageRank global (*lift*), y su calidad depende directamente de cómo se definan las semillas.

Referencias

[1] Taher H. Haveliwala. Topic-sensitive pagerank. In *Proceedings of the 11th International World Wide Web Conference (WWW)*, pages 517–526, 2002.

[2] Jon M. Kleinberg. Authoritative sources in a hyperlinked environment. *Journal of the ACM*, 46(5):604–632, 1999.

[3] Jure Leskovec, Jon Kleinberg, and Christos Faloutsos. Graph evolution: Densification and shrinking diameters. *ACM Transactions on Knowledge Discovery from Data*, 1(1), 2007.

[4] Jure Leskovec, Anand Rajaraman, and Jeffrey Ullman. *Mining of Massive Datasets*. Cambridge University Press, Delhi, 2016.

[5] Lawrence Page, Sergey Brin, Rajeev Motwani, and Terry Winograd. The pagerank citation ranking: Bringing order to the web. Technical report, Stanford InfoLab, 1999.